

工業技術研究院

Industrial Technology
Research Institute

TSiP x AI Hub

題目：AI Hub軟體工具應用平台 規劃說明




報告人：電光系統所 陳冠穎

簡報日期：

目標市場與情境構想摘要

產業痛點

邊緣 AI 缺乏可供產業採用的**共同參考標準**，造成市場**信心不足**與**重複試錯**成本高，難以形成生態擴散。



工具鏈差異

異質硬體的協定/軟體堆疊，導致整合與維運的難度高。

缺乏參考依據

晶片/框架組合爆炸成長，缺乏可比較的基準；難以支撐企業採用決策。

難以商業化

缺乏共通且可大規模部署的方法，營運與維護多停留在專案等級。

解決 LLM缺乏大規模導入模式 的問題

技術趨勢



【經濟日報報導】Skymizer Taiwan Inc. 發表突破性架構 單卡實現超大型 LLM 推論

ALL 全部 | 技術趨勢 | 2026-04-24

【經濟日報報導】Skymizer Taiwan Inc. 發表突破性架構 單卡實現超大型 LLM 推論2026/04/23 20:00:43美通社 贊助提供原文連結：

<https://money.udn.com/money/story/123828/9460682...>

▶ 【工商時報報導】與國際ASIC大廠比拚 聯發科進軍Micro LED光通訊 能否全面商用...

ALL 全部 | 2026-04-21 | 技術趨勢

▶ 【DIGITIMES報導】AMD以算力引領台灣產業加速AI應用創新與實踐

ALL 全部 | 2026-04-17 | 技術趨勢

▶ 【中時新聞網報導】工研院辦國際研討會 聚焦生成式 AI、量子運算與跨域整合

ALL 全部 | 2026-04-16 | 技術趨勢

@資料來自 2026/05/06 台灣人工智慧晶片聯盟(AITA)

HTX301

Ryzen AI
Radeon
Instinct

僅支援展示或一次性專案

AI PC促換機潮是假的！電腦大廠罕見坦承：消費者根本不在乎

2026/01/08 13:00
文 / 紀傳禹攝

5000億美元「星際之門」AI計畫雷聲大雨點小？三大困境與專家質疑

JuRood發佈於 JuRood Fish_科技趣事
2025/07/27 更新 · 2025/07/27 發佈 · 閱讀 5 分鐘

今年年初，**星際之門計畫 (The Stargate Project)**由白宮盛大揭幕，由OpenAI、軟銀、甲骨文等AI巨頭和投資公司 MGX 聯合創立的**AI企業**；這個由美國總統川普所高調宣布的計畫，目標是推動美國的人工智慧技術與專案，使美國在全球競爭中更具優勢。

六個多月後的今天，價值5000億美元的Stargate計畫因難以尋得合作夥伴，據說已陷入停滯，並被迫縮減其遠大抱負。雖然本週Oracle與OpenAI達成協議，[要在美國增建4.5Gigawatt \(GW\)的Stargate資料中心容量](#)，但具體怎麼建卻存在很多問題。

「AI PC」真的帶來換機潮了嗎？這恐怕只是一個假象，電腦大廠並不在乎AI PC。」

根據外匯報導 在於AI功能，15 天前

AI更新太快78人才跟不上 Cake調查台灣Edge AI缺口

有房就可以貸，讓資產產生穩定現金流

雙SSR強勢登場！鑽明閃擊 推全場治療「貝拉...


比買電視更划算！百吋大螢幕，小客廳瞬間...

《鑽明閃擊》首個全場治療SSR病嬌抖M-貝拉...

【許家源記者 / 綜合報導】

根據Cake最新調查，78%的受訪者傾向「應用型角色」，這組數據背後反映台灣企業正全力衝刺AI快速落地解決商業痛點，市場對能將工具直接轉成生產力的應用端人才需求最急迫。長期追蹤矽谷與半導體產業發現，這並非底層架構的徹底斷裂，而是台灣發揮全球頂尖半導體與資訊硬體製造優勢的關鍵轉型時刻。Cake媒體發言人Helen Chung指出，台灣硬體基礎雄厚，未來挑戰不在從零培養新人，而是協助既有硬體、軟體與系統工程師跨域學習AI模型優化與部署，讓企業內部技術人才快速轉型，避開人才缺口並持續握有國際供應鏈競爭力。

系統架構及具體交付項目



應用研發的橋梁 Inference Benchmark



Google 公布Gemma 3 成果 (Q1 2025)

- [Gemma 3 Technical Report](#)



ASUS 推出Ryzen AI系列PC (Q4 2025)




[Expert Center PN54](#)



[NUC 14 Pro AI](#)

於HuggingFace 全面開源模型 (Q1 2026)



AMD 釋出NPU最佳化的版本 (Q2 2026)

1.7 1.6 1.5 1.4 1.3 1.2 1.1 1.0

1.7 Release Highlights

- New architectures first releases of Mixture of Experts (MoE) GPT-OSS and VLM (Gemma-3 4B)
- Stable Diffusion integrated into the main Ryzen AI installer for a unified environment
- LLMs now support up to 16K context length
- BF16 pipeline delivers ~2x lower latency vs. RAI 1.6

[Ryzen AI Software版本更新](#)

生產後驗證 Minimum Viable Profile

- **SLA 核心門檻**：推論效能需具備可見性，才有資格進入使用者的候選名單。
- **關鍵性能指標**：提供系統與**Repository**，保證能取得平台公布的性能。

面向	代表性指標	判定規範
可用性 (共2項)	有效回應率	在服務期間，≥99.X% 的請求符合 API 規格
效能 (共5項)	首次回應時間 (TTFT, P95)	在指定輸入條件下，95% 的請求 TTFT 不得超過 X ms
資源需求 (共3項)	記憶體峰值 (Peak Memory)	在指定模型與設定下，加速器記憶體峰值不得超過 X GB
穩定性 (共2項)	長時間運作錯誤率 (Soak Test)	在連續 X 小時運行期間，整體錯誤率不得高於 Y%
可驗證性 (共4項)	版本指紋完整度 (Traceability)	Benchmark條件已被明確定義，使第三方可進行等價比較。
可重現性 (共2項)	一致性	在相同條件下重跑 N 次，關鍵指標需有 ≥M% 的結果落在一致性範圍內


Gemma3 on PN54

模型選項
(Model Option)

軟體堆疊
(Software Stack)

硬體驅動
(Hardware Driver)

主系統
(Operation System)



99%的開發人員
第一步就會遇到相容性的瓶頸

```
Phi-4-mini-instruct-onnx-ryzenai-npu --prompt "請
src\ops\op_builder.cpp:114] [ERROR] OpBuilder::create() fa

Details:
OpName: MatMulNBits_2_0
OpType: MladdfMatMul
Provided arg dtypes: 0:bfloat16 1:int8 2:float 3:float 4:int8 5:bfloat16
Error: [C:\Users\zlaiebuild\dod\src\ops\llm_ops\llm_common\llm_common.cpp:162] [ERROR] flat version is not supported for matmulbias2026-05-06 16:
25:29.0132425 [E:onnxruntime:genai, inference_session.cc:2545 onnxruntime::InferenceSession::Initialize::(lambda_8831dda887db34e19b24f3
92bad0a853)::operator ()] Exception during initialization: [C:\Users\zlaiebuild\dod\src\ops\op_builder.cpp:114] [ERROR] OpBuilder::create() failed.
Details:
OpName: MatMulNBits_2_0
OpType: MladdfMatMul
Provided arg dtypes: 0:bfloat16 1:int8 2:float 3:float 4:int8 5:bfloat16
Error: [C:\Users\zlaiebuild\dod\src\ops\llm_ops\llm_common\llm_common.cpp:162] [ERROR] flat version is not supported for matmulbias
Traceback (most recent call last):
File "C:\Program Files\RyzenAI\1.7.1\LLM\example\model_chat.py", line 513, in <module>
main(args)
File "C:\Program Files\RyzenAI\1.7.1\LLM\example\model_chat.py", line 247, in main
model = og.Model(config)
RuntimeError: Exception during initialization: [C:\Users\zlaiebuild\dod\src\ops\op_builder.cpp:114] [ERROR] OpBuilder::create() failed.
```

應用研發擴散 Playground Demo

除測試用CLI，另提供兩種使用介面

1. 整合Python SDK

```
from openai import OpenAI
client = OpenAI(base_url="http://localhost:8000/v1", api_key="local")



for chunk in client.chat.completions.create(
    model="ryzen-ai-gemma3-4b-npu", stream=True,
    messages=[{"role": "user", "content": "解釋量子計算"}],
):
    print(chunk.choices[0].delta.content or "", end="", flush=True)
```

2. API Endpoint及Open WebUI

```
docker pull ai-hub/ryzen-ai-gemma3-4b-npu:latest
docker run -d -p 8080:80 ai-hub/ryzen-ai-gemma3-4b-npu:latest
```

Then open `http://localhost:8080` .

```
curl http://localhost:8080/api/generate -d '{
  "model": "gemma4", "prompt": "Hello!"
}'
```



推論過程服務化 Model Deployment

現況 (Q1 2026)

已完成的項目

- PN54 - Gemma3 on NPU
- VivoBook S15/16 - Gemma4 on GPU

一鍵選用
自動化部署



項目	閉源生態 (AMD Lemonade)
① 跨平台部署	
② 模型多元性	低
③ 可異質Offload	✓

AI Hub (預計使用Docker)
✓
高
✓

開源生態 (Ollama、LMStudio)
✓
中
有限

支援應用服務框架 Application Integration




[Generative Agents: Interactive Simulacra of Human Behavior \(2023\)](#)

```
python cli.py --model gemma3-4b-npu \
--prompt "Let's think step by step..."
```

↓ Powered by AI Hub API

□ AI服務節點
■ 上下文管理
→ 工作流




通路及生態佈局

ReAct服務節點 (截至Q2 2026)

Perceive	Plan	Retrieve	Reflect	Action
Multi-modal Conversation	Agentic Reasoning	Knowledge Representation	Token-expiry Handling	Embodied Execution

全球產業生態

AI Agents



皆是以單點起家，獲VC創投/併購的新創公司及團隊

工研院角色

AI Chips

(合作廠商/ 參與學校)

UXUI規劃

- 應用情境：描述解決方案的主要價值和獨特賣點
- 系統工作流程：描述使用者從開始至結束使用本方案的步驟與流程（MVD）

會議記錄

建議可先以既有SLM組合，找出可支撐多模型組合的實作方式，逐步建立平台在模型整合、服務化的核心能力。

YOLOv8 MediaTek Genio EVB		Gemma-3 4B AMD Mini PC	Gemma-4 E2B/E4B AMD AI Laptop
部門/ 應用領域	問題探討	觀點	
資通 生成式AI Workflow	從SLM應用開發角度，在實際導入生成式AI應用（如PLC與工業場域）時，單一模型僅為推論節點，需透過多模型組合與流程編排完成任務。	建議支援多模型節點整合與調度，並提供標準化API與流程編排，使模型以服務節點組合運作；同時具備效能（如token/sec）、資源與穩定性可視化，支援開發者依需求串接模型，確保落地能力。	
T500 生成式AI 製造Tool	指出目前多數AI系統（如Cursor、OpenClaw、Harness）皆以ReAct為核心框架，並在其上延伸不同應用場景，顯示應用層具備良好擴展能力。	討論是否需建立統一的framework；或基於既有的開源架構（如ReAct）持續擴展與整合能力（如reflect、memory）。	
R300 生成式AI 醫療Tool	認為ReAct-based應用落地擴散的首要瓶頸在於SLM部署，關鍵在於選擇可運行、效能足夠且符合SDK需求的邊緣硬體與模型組合。	提出模型小卡（Model Card）與SLM API，將複雜的分析與整合單一服務節點的流程轉化為可直接套用的選擇。	
T300 鑑別式AI	指出，國內晶片若要支援這些AI模型，軟體堆疊隨模型與框架快速擴展而呈指數成長，難形成如大廠（NVIDIA、AMD、Intel）之完整支援體系。	傳統以補齊driver與compiler支援鑑別式AI的方式已面臨瓶頸；生成式AI帶動堆疊複雜度提升，未來可能需透過產業生態聯盟或軟體協議等方式因應。	

預期效益